

Résumé des résultats — these_adv

Projet these_adv

16 juillet 2026

1. Performance clean (seuil = 0.5, test set)

Dataset	Modèle	F1	Précision	Rappel	Accuracy
SWaT	MLP	0.948	0.907	0.992	99.59%
SWaT	LogReg	0.478	0.328	0.880	92.71%
SWaT	XGBoost	0.999	0.998	1.000	99.99%
BATADAL	MLP	0.101	0.055	0.705	69.32%
BATADAL	LogReg	0.425	0.293	0.773	94.88%
BATADAL	XGBoost	0.966	0.977	0.955	99.83%

Tailles réelles — SWaT : 51 features, train 922 700 / val 230 675 / test 288 344 lignes. BATADAL : 43 features, train 5 747 / val 1 437 / test 1 796 lignes.

2. ASR baseline (modèles NON défendus), $\epsilon = 0.1$

Médiane sur 10 seeds (5 pour BATADAL decision-based sous-échantillonné).

ASR = fraction des vraies attaques détectées en clean qui deviennent classées « normal » après perturbation.

Famille	Attaque	SWaT MLP	SWaT LogReg	SWaT XGBoost	BATADAL MLP	BATADAL LogReg	BATADAL XGBoost
White-box (gradient exact/ approché)	FGSM	16.6%	18.5%	33.0%	22.58%	47.06%	88.1%
	PGD	20.6%	18.5%	43.9%	22.58%	47.06%	80.95%
	C&W	20.6%	18.5%	44.5%	22.58%	47.06%	80.95%
Black-box score-based	Square	20.5%	18.5%	80.9%	22.58%	47.06%	83.33%
	NES	19.7%	18.4%	88.5%	22.58%	47.06%	92.86%
Black-box decision-based	HSJA	8.0%	8.83%	83.33%	16.13%	20.59%	92.86%
	RayS	12.17%	12.17%	87.33%	19.35%	39.71%	95.24%
Transfert (substituts, 0 requête)	MI-FGSM (Sub1/2/3)	16.2– 17.7%	6.4– 8.6%	32.3– 33.4%	6.45– 12.9%	11.76– 29.41%	63.09– 82.14%
	VMI-FGSM (Sub1/2/3)	15.9– 17.7%	6.5– 8.1%	32.8– 33.0%	6.45– 12.9%	10.29– 29.41%	64.28– 82.14%
		17.6%	9.1%	33.0%	11.29%	27.94%	75.0%

Famille	Attaque	SWaT MLP	SWaT LogReg	SWaT XGBoost	BATADAL MLP	BATADAL LogReg	BATADAL XGBoost
	Ensemble- MI (3 substituts)						

Constat central : sur les deux datasets et toutes les familles d'attaque, XGBoost (quasi parfait en clean) est systématiquement le plus fragile (ASR jusqu'à 95.2%), tandis que MLP et LogReg (moins précis en clean) restent nettement plus robustes (ASR souvent 8–30%). Performance clean et robustesse adverse sont anti-corrélées.

3. Défenses évaluées

Sept modèles durcis par dataset, entraînés à $\epsilon_{AT} = 0.3$:

Défense	Modèle de base	Méthode
AT-FGSM	MLP	Adversarial training online (FGSM à chaque batch, mix 50%)
AT-PGD	MLP	Idem, PGD (7 iters, 1 restart)
AT-Square	MLP	Augmentation itérative offline (Square, 3 rounds)
Aug-FGSM	LogReg	Augmentation adverse one-shot (FGSM)
Aug-Square	LogReg	Augmentation adverse one-shot (Square)
Aug-FGSM-Iter	XGBoost	Augmentation itérative self (FGSM, 3 rounds, refit from scratch)
Aug-Square-Iter	XGBoost	Idem avec Square

Correctif appliqué le 16/07/2026 : la première version de `augment_logreg` (dans `defenses.py`) refittait la régression logistique augmentée avec $C=1.0$ fixe. Pour un modèle linéaire, la sensibilité L_∞ dépend du ratio $\text{marge}/\|w\|_1$, pas de la marge seule — or l'augmentation adverse (exemples poussés vers la zone « normal » mais toujours étiquetés attaque) force $\|w\|_1$ à exploser sous faible régularisation ($\times 4$ sur SWaT), ce qui RÉDUIT la marge effective. Résultat observé initialement : la défense LogReg augmentait l'ASR au lieu de la baisser (jusqu'à +32 points). Vérifié empiriquement (reproduction exacte du modèle sauvegardé, balayage de C) puis corrigé : C est maintenant choisi par grid search sur X_{val} (jamais X_{test}), en maximisant le score combiné $F1 - ASR(\text{FGSM}, \epsilon=0.1)$. Les deux modèles LogReg défendus ont été réentraînés et toutes les évaluations ci-dessous ont été refaites avec les nouveaux modèles. Les anciens résultats (bug) sont archivés dans `results/_backup_buggy_logreg_20260715/`.

3.1 Évaluation adaptative WHITE-BOX (attaque relancée directement contre le modèle durci)

Seules 4 défenses couvertes par `evaluate.py` (une par modèle de base pour FGSM/PGD/C&W).

Dataset	Modèle / Défense	FGSM (base → défendu, Δ)	PGD (base → défendu, Δ)	C&W (base → défendu, Δ)
SWaT	MLP / AT-FGSM	16.6 → 3.8% (-12.8)	20.6 → 4.4% (-16.2)	20.6 → 4.4% (-16.2)
SWaT	MLP / AT-PGD	16.6 → 0.6% (-16.0)	20.6 → 0.6% (-20.0)	20.6 → 0.6% (-20.0)
SWaT	LogReg / Aug-FGSM	18.5 → 10.6% (-7.9)	18.5 → 10.6% (-7.9)	18.5 → 10.6% (-7.9)
SWaT	XGBoost / Aug-FGSM-Iter	33.0 → 6.6% (-26.4)	43.9 → 23.0% (-20.9)	44.5 → 18.2% (-26.3)
BATADAL	MLP / AT-FGSM	22.58 → 9.1% (-13.5)	22.58 → 9.1% (-13.5)	22.58 → 9.1% (-13.5)
BATADAL	MLP / AT-PGD	22.58 → 4.8% (-17.8)	22.58 → 4.8% (-17.8)	22.58 → 4.8% (-17.8)
BATADAL	LogReg / Aug-FGSM	47.06 → 10.0% (-37.1)	47.06 → 10.0% (-37.1)	47.06 → 10.0% (-37.1)
BATADAL	XGBoost / Aug-FGSM-Iter	88.1 → 12.5% (-75.6)	80.95 → 27.5% (-53.5)	80.95 → 20.0% (-61.0)

Après correction, AT-PGD (MLP) et Aug-FGSM (LogReg, BATADAL) sont les défenses les plus efficaces en white-box — toutes les défenses réduisent maintenant l'ASR par rapport au baseline, sur les deux datasets.

3.2 Évaluation adaptative BLACK-BOX — moyenne par famille d'attaque

Matrice complète des 7 défenses (*evaluate_blackbox.py*), médiane par famille (Score = Square+NES ; Decision = HSJA+RayS ; Transfer = MI-FGSM+VMI-FGSM×3 substituts+Ensemble-MI).

Dataset	Modèle / Défense	Score défendu (base)	Decision défendu (base)	Transfer défendu (base)
SWaT	LogReg / Aug-FGSM	10.5% (18.4%)	7.3% (10.5%)	1.7% (7.5%)
SWaT	LogReg / Aug-Square	11.6% (18.4%)	5.5% (10.5%)	8.4% (7.5%)
SWaT	MLP / AT-FGSM	4.3% (20.1%)	2.5% (10.1%)	3.6% (17.1%)
SWaT	MLP / AT-PGD	0.6% (20.1%)	0.3% (10.1%)	0.2% (17.1%)
SWaT	MLP / AT-Square	14.9% (20.1%)	1.0% (10.1%)	0.0% (17.1%)
SWaT	XGBoost / Aug-FGSM-Iter	34.2% (84.7%)	28.5% (85.3%)	4.9% (33.0%)
SWaT	XGBoost / Aug-Square-Iter	10.7% (84.7%)	0.0% (85.3%)	0.0% (33.0%)
BATADAL			0.0% (30.1%)	1.4% (20.6%)

Dataset	Modèle / Défense	Score défendu (base)	Decision défendu (base)	Transfer défendu (base)
	LogReg / Aug-FGSM	10.0% (47.1%)		
BATADAL	LogReg / Aug-Square	0.0% (47.1%)	0.0% (30.1%)	0.0% (20.6%)
BATADAL	MLP / AT-FGSM	9.1% (22.6%)	4.5% (17.7%)	4.5% (9.0%)
BATADAL	MLP / AT-PGD	4.8% (22.6%)	0.0% (17.7%)	0.0% (9.0%)
BATADAL	MLP / AT-Square	23.4% (22.6%)	12.5% (17.7%)	11.2% (9.0%)
BATADAL	XGBoost / Aug-FGSM-Iter	37.5% (88.1%)	36.2% (94.0%)	12.5% (71.8%)
BATADAL	XGBoost / Aug-Square-Iter	30.0% (88.1%)	15.0% (94.0%)	0.4% (71.8%)

Lecture : une défense entraînée contre le black-box par requêtes (Square) réduit aussi les ASR decision-based (HSJA/RayS) et transfert (MI-FGSM), preuve d'un transfert de robustesse entre familles d'attaque. Après correction, **LogReg/Aug-Square sur BATADAL est la meilleure défense de tout le tableau** (quasi 0% sur les trois familles, alors que le baseline était déjà le plus faible modèle du dataset). XGBoost, le plus fragile en baseline, bénéficie aussi énormément des défenses (chutes de 50 à 90 points). Seul XGBoost/Aug-FGSM-Iter reste avec un ASR résiduel notable (28–38%) sur SWaT/BATADAL — la piste Aug-Square-Iter est nettement plus efficace pour ce modèle.

3.3 Détail complet par attaque — évaluation black-box adaptative (appendice)

SWaT

Modèle / Défense	Attaque	ASR défendu	ASR baseline	Δ
MLP / AT-PGD	Square	0.6%	20.5%	−19.9
MLP / AT-PGD	NES	0.6%	19.7%	−19.1
MLP / AT-PGD	HSJA	0.33%	8.0%	−7.67
MLP / AT-PGD	RayS	0.33%	12.17%	−11.84
MLP / AT-PGD	Ensemble-MI	0.2%	17.6%	−17.4
MLP / AT-FGSM	Square	4.4%	20.5%	−16.1
MLP / AT-FGSM	NES	4.2%	19.7%	−15.5
MLP / AT-FGSM	HSJA	1.33%	8.0%	−6.67
MLP / AT-FGSM	RayS	3.67%	12.17%	−8.5
MLP / AT-FGSM	Ensemble-MI	3.6%	17.6%	−14.0
MLP / AT-Square	Square	14.8%	20.5%	−5.7
MLP / AT-Square	NES	15.0%	19.7%	−4.7
MLP / AT-Square	HSJA	1.33%	8.0%	−6.67
MLP / AT-Square	RayS	0.67%	12.17%	−11.5

Modèle / Défense	Attaque	ASR défendu	ASR baseline	Δ
MLP / AT-Square	Ensemble-MI	0.0%	17.6%	-17.6
LogReg / Aug-FGSM	Square	10.6%	18.5%	-7.9
LogReg / Aug-FGSM	NES	10.4%	18.4%	-8.0
LogReg / Aug-FGSM	HSJA	6.67%	8.83%	-2.16
LogReg / Aug-FGSM	RayS	8.0%	12.17%	-4.17
LogReg / Aug-FGSM	Ensemble-MI	1.4%	9.1%	-7.7
LogReg / Aug-Square	Square	11.6%	18.5%	-6.9
LogReg / Aug-Square	NES	11.6%	18.4%	-6.8
LogReg / Aug-Square	HSJA	3.67%	8.83%	-5.16
LogReg / Aug-Square	RayS	7.33%	12.17%	-4.84
LogReg / Aug-Square	Ensemble-MI	9.0%	9.1%	-0.1
XGBoost / Aug-FGSM-Iter	Square	33.8%	80.9%	-47.1
XGBoost / Aug-FGSM-Iter	NES	34.6%	88.5%	-53.9
XGBoost / Aug-FGSM-Iter	HSJA	28.67%	83.33%	-54.66
XGBoost / Aug-FGSM-Iter	RayS	28.33%	87.33%	-59.0
XGBoost / Aug-FGSM-Iter	Ensemble-MI	5.0%	33.0%	-28.0
XGBoost / Aug-Square-Iter	Square	21.4%	80.9%	-59.5
XGBoost / Aug-Square-Iter	NES	0.0%	88.5%	-88.5
XGBoost / Aug-Square-Iter	HSJA	0.0%	83.33%	-83.33
XGBoost / Aug-Square-Iter	RayS	0.0%	87.33%	-87.33
XGBoost / Aug-Square-Iter	Ensemble-MI	0.0%	33.0%	-33.0

BATADAL

Modèle / Défense	Attaque	ASR défendu	ASR baseline	Δ
MLP / AT-PGD	Square	4.76%	22.58%	-17.82
MLP / AT-PGD	NES	4.76%	22.58%	-17.82
MLP / AT-PGD	HSJA	0.0%	16.13%	-16.13
MLP / AT-PGD	RayS	0.0%	19.35%	-19.35
MLP / AT-PGD	Ensemble-MI	0.0%	11.29%	-11.29

Modèle / Défense	Attaque	ASR défendu	ASR baseline	Δ
MLP / AT-FGSM	Square	9.09%	22.58%	-13.49
MLP / AT-FGSM	NES	9.09%	22.58%	-13.49
MLP / AT-FGSM	HSJA	4.55%	16.13%	-11.58
MLP / AT-FGSM	RayS	4.55%	19.35%	-14.8
MLP / AT-FGSM	Ensemble-MI	4.55%	11.29%	-6.74
MLP / AT-Square	Square	25.0%	22.58%	+2.42
MLP / AT-Square	NES	21.88%	22.58%	-0.7
MLP / AT-Square	HSJA	9.38%	16.13%	-6.75
MLP / AT-Square	RayS	15.62%	19.35%	-3.73
MLP / AT-Square	Ensemble-MI	15.62%	11.29%	+4.33
LogReg / Aug-FGSM	Square	10.0%	47.06%	-37.06
LogReg / Aug-FGSM	NES	10.0%	47.06%	-37.06
LogReg / Aug-FGSM	HSJA	0.0%	20.59%	-20.59
LogReg / Aug-FGSM	RayS	0.0%	39.71%	-39.71
LogReg / Aug-FGSM	Ensemble-MI	0.0%	27.94%	-27.94
LogReg / Aug-Square	Square	0.0%	47.06%	-47.06
LogReg / Aug-Square	NES	0.0%	47.06%	-47.06
LogReg / Aug-Square	HSJA	0.0%	20.59%	-20.59
LogReg / Aug-Square	RayS	0.0%	39.71%	-39.71
LogReg / Aug-Square	Ensemble-MI	0.0%	27.94%	-27.94
XGBoost / Aug-FGSM-Iter	Square	32.5%	83.33%	-50.83

Modèle / Défense	Attaque	ASR défendu	ASR baseline	Δ
XGBoost / Aug-FGSM-Iter	NES	42.5%	92.86%	-50.36
XGBoost / Aug-FGSM-Iter	HSJA	35.0%	92.86%	-57.86
XGBoost / Aug-FGSM-Iter	RayS	37.5%	95.24%	-57.74
XGBoost / Aug-FGSM-Iter	Ensemble-MI	12.5%	75.0%	-62.5
XGBoost / Aug-Square-Iter	Square	35.0%	83.33%	-48.33
XGBoost / Aug-Square-Iter	NES	25.0%	92.86%	-67.86
XGBoost / Aug-Square-Iter	HSJA	20.0%	92.86%	-72.86
XGBoost / Aug-Square-Iter	RayS	10.0%	95.24%	-85.24
XGBoost / Aug-Square-Iter	Ensemble-MI	2.5%	75.0%	-72.5

Note : les lignes transfert (MI-FGSM/VMI-FGSM par substitut) sont omises ici pour la lisibilité — Ensemble-MI en est représentatif (écart typique < 5 points avec les substituts individuels).

4. Remarques méthodologiques

1. Protocole commun à toutes les attaques : eval set = uniquement les vrais positifs clean, 10 seeds (médiane/std/min/max rapportés), seuil unique 0.5, $\epsilon=0.1$ pour toutes les attaques ($\epsilon=0.3$ réservé à l'entraînement des défenses).
2. BATADAL a une variance à 0 fréquente (std=0 sur FGSM/PGD/C&W MLP/LogReg) — artefact du très petit nombre d'attaques test (44), à mentionner comme limite de significativité statistique par rapport à SWaT (10 000+ attaques test).
3. Sur LogReg, FGSM/PGD/C&W donnent souvent des ASR identiques — cohérent théoriquement (modèle linéaire sous contrainte L_∞ , direction optimale $\approx \text{sign}(w)$ quel que soit l'algorithme).
4. Gradient XGBoost approché par différences finies centrées avec vote multi- ϵ (stabilise l'estimation sur une fonction en escalier bruitée) — c'est ce qui rend possible d'attaquer XGBoost en white-box malgré l'absence de gradient analytique.
5. HSJA et RayS ont été entièrement réécrits/batchés (gain d'un à deux ordres de grandeur en temps de calcul) par rapport à la version initiale qui appelait `predict()` exemple par exemple.

6. Couverture désormais complète (16 juillet 2026) : white-box baseline + black-box baseline (score/decision/transfert) + white-box adaptatif (4 défenses) + black-box adaptatif (7 défenses), sur les deux datasets. Reste en attente : balayage $\epsilon=0.3$ pour les attaques (actuellement seulement utilisé pour l'AT).
7. **Bug identifié et corrigé (16/07/2026)** : `augment_logreg` (`defenses.py`) refittait la LogReg augmentée avec `C=1.0` fixe, ce qui faisait exploser $\|w\|_1$ ($\times 4$ sur SWaT) et RÉDUISAIT la marge L_∞ effective (= $\text{marge}/\|w\|_1$ pour un modèle linéaire) — la défense augmentait l'ASR au lieu de la baisser (jusqu'à +32 points). Diagnostiqué par reproduction exacte du modèle sauvegardé + balayage empirique de `C` (confirmé sur les deux datasets). Corrigé par sélection de `C` par grid search sur `X_val` (score combiné F1 – ASR à $\epsilon=0.1$, jamais sur `X_test`). Après correction, Aug-FGSM/Aug-Square sur LogReg deviennent des défenses parmi les plus efficaces du tableau (BATADAL/Aug-Square : ASR quasi nul sur toutes les familles d'attaque). Bon exemple, pour l'article, du piège classique de l'adversarial training sur modèle linéaire sans contrôle de la norme des poids.